

Pontifícia Universidade Católica de Minas Gerais
Tecnologia em Banco de Dados - EAD
Graduação Virtual

Alberto Santana Santos
Alessandro Junio Lopes Rodrigues
Gabriel Figueiredo do Nascimento
João Victor de Andrade Guedes
Lucas Naves da Silveira
Luiza Gonçalves Zacarias

**Plataforma de dados para priorização de leads e análise do custo de
aquisição de clientes**

Etapa 2 — Replicação e integração dos dados

Projeto apresentado ao Curso de Tecnologia em Banco de Dados da Pontifícia Universidade Católica de Minas Gerais, como requisito parcial da Etapa 2 do Projeto de Big Data Analytics — Eixo 4.

Orientador: Prof. Marco Paulo

Belo Horizonte
2026

SUMÁRIO

1 INTRODUÇÃO	3
2 A EMPRESA	3
2.1 Ramo de Atuação, Porte e Produtos	3
2.2 Recursos de TI	3
3 O PROBLEMA	4
4 A EMPRESA E A SOCIEDADE DIGITAL	4
5 BASES DE DADOS	5
5.1 Origens e Conteúdo	5
5.2 Ferramenta Utilizada na Geração	6
6 MODELAGEM DOS DADOS	7
6.1 Modelo Conceitual	7
6.2 Modelo do Armazém de Dados	7
7 ARQUITETURA E INTEGRAÇÃO	8
7.1 Infraestrutura	8
7.2 Processo de Integração	9
8 CUSTOS	9
9 REPOSITÓRIO	10
10 REFERÊNCIAS	11

1 INTRODUÇÃO

Castells (1999) caracteriza a sociedade contemporânea como uma sociedade em rede: a informação se torna a matéria-prima da atividade econômica, e a rede, viabilizada pelas tecnologias de informação e comunicação, passa a ser a forma predominante de organizar a produção, o trabalho e o consumo. Nessa configuração, a tecnologia não é algo que se acrescenta a um negócio já formado — é em torno dela que o negócio se estrutura.

A Nexo Sistemas, organização **fictícia** tomada como objeto deste projeto, vende software de gestão por assinatura para pequenas empresas do varejo e se caracteriza como empresa dessa sociedade em rede em todas as frentes. Vende à distância, sem visita presencial; entrega um produto que só funciona em nuvem; e encontra seus clientes por busca e anúncio na internet, em plataformas de mídia cujas regras não controla. Mais do que isso, o que ela vende é a digitalização de outros negócios: cada contrato fechado tira um pequeno lojista do caderno e da planilha e o coloca num sistema conectado.

O projeto consiste em construir, para ela, uma plataforma de dados que reúna informações hoje espalhadas em sistemas separados, de modo que a empresa consiga priorizar o atendimento aos interessados com maior chance de fechar negócio e saber quanto custa, em cada canal, conquistar um cliente.

2 A EMPRESA

2.1 Ramo de Atuação, Porte e Produtos

A Nexo Sistemas atua no ramo de desenvolvimento e licenciamento de software. Seu produto reúne frente de caixa, controle de estoque, emissão de notas fiscais e gestão financeira, e é vendido por assinatura mensal. Foi fundada em 2016, fica em Belo Horizonte e opera de forma remota: a venda é feita à distância, por um time comercial próprio, e a implantação acontece sem visita presencial.

A empresa tem **70 funcionários**: 30 na área comercial, 18 em desenvolvimento, 12 em suporte e 10 no administrativo, financeiro e TI. Atende cerca de 2.500 clientes e fecha aproximadamente mil novos contratos por ano, com receita anual em torno de R\$ 10,9 milhões. Pelo número de funcionários e pelo faturamento, é classificada como **média empresa**.

São vendidos três planos de assinatura, que se diferenciam pelo porte do cliente e pelos recursos liberados.

Quadro 1 – Produtos comercializados

Plano	Mensalidade (R\$)	Perfil de cliente	Clientes ativos
Essencial	190	Microempresas e autônomos	1.100
Profissional	390	Pequenas empresas	1.150
Corporativo	990	Médias empresas e redes de lojas	250

Fonte: elaborado pelos autores (2026).

2.2 Recursos de TI

A empresa não tem servidores próprios. O produto e os sistemas internos rodam em nuvem contratada como serviço, e o hardware se resume aos notebooks dos funcionários, aos headsets do time comercial e ao link de internet da sede.

Em software, a operação comercial se apoia em três fontes de informação, mantidas separadamente, que serão as origens de dados do projeto:

- **CRM**, com os contatos, as oportunidades e as etapas da venda;
- **Plataforma de anúncios**, com o quanto foi investido e o que cada campanha trouxe;
- **Planilhas do time comercial**, com as metas de cada vendedor, as faixas de comissão e a apuração refeita à mão todo mês.

Há ainda a base de uso do próprio produto, que registra o que cada cliente faz no sistema. É a maior de todas em quantidade de registros, mas hoje não é aproveitada fora do suporte.

Em serviços de TI, quase tudo é contratado por assinatura, mais o suporte técnico terceirizado e a hospedagem em nuvem. A equipe de tecnologia cuida só do produto: não existe ninguém dedicado a dados na operação comercial.

3 O PROBLEMA

A Nexo recebe cerca de 3.000 oportunidades de venda por mês e fecha negócio com 3% delas. O time comercial atende por ordem de chegada, e não por quem tem mais chance de comprar, simplesmente porque não existe critério para ordenar a fila: 31% do que entra não recebe nenhum contato em 72 horas, justo o período em que o interesse ainda está quente.

Ao mesmo tempo, o custo para conquistar um cliente — somando o investimento em anúncios e a comissão paga na venda — subiu de R\$ 900 para R\$ 1.450 em dois anos, e a empresa não consegue dizer qual canal ou qual plano está puxando essa alta. O motivo é sempre o mesmo: o investimento em anúncio está numa plataforma, o histórico da negociação está no CRM, as metas e a comissão estão em planilhas, e nada disso se conversa. Pelo mesmo motivo, a comissão do time comercial é reapurada à mão a cada virada de mês.

O projeto pretende responder a duas perguntas: como ordenar a fila de atendimento por chance de conversão, e quanto custa conquistar um cliente em cada canal e em cada plano. Para isso, os dados do funil serão gerados de forma sintética, reproduzindo só a estrutura do negócio.

4 A EMPRESA E A SOCIEDADE DIGITAL

Hoje a Nexo usa tecnologia só para operar, não para decidir. Com a plataforma de dados, isso muda de três formas. O trabalho do vendedor muda, porque ele deixa de escolher a quem ligar e passa a seguir uma fila ordenada. As competências mudam, porque a empresa vai precisar de gente de dados, função que hoje não existe. E a responsabilidade aumenta, porque juntar num só lugar os dados de todos os sistemas cria um ponto único de risco, o que exige controle de acesso e regra clara sobre por quanto tempo cada dado é guardado.

Do lado da sociedade, o ponto sensível é quem a empresa decide atender primeiro. Uma fila ordenada por potencial econômico tende a priorizar o cliente maior e deixar o microempreendedor para o final — justamente quem mais ganharia com o controle que o produto oferece. Por isso o grupo assume desde já duas regras: a ordenação organiza a fila, mas não exclui ninguém dela, garantindo um prazo máximo para o primeiro contato; e o critério usado para ordenar fica documentado e aberto ao time comercial. Vale lembrar ainda que a lei brasileira garante ao cliente o direito de pedir revisão de decisões tomadas só por máquina (BRASIL, 2018).

Na outra direção, a sociedade digital também mexe com a empresa. Mudanças em obrigações fiscais eletrônicas provocam picos de procura por sistemas de gestão, e ela precisa antecipar isso para dimensionar equipe e verba de anúncio. E como depende de plataformas de mídia cujas regras mudam sem aviso, seu custo de aquisição é em parte decidido por terceiros — o que reforça a necessidade de ter medição própria.

5 BASES DE DADOS

5.1 Origens e Conteúdo

Como a Nexo é fictícia, os dados das três origens foram gerados por um programa em Python, com semente fixa: rodar de novo produz exatamente os mesmos arquivos. A janela é de seis meses, de março a agosto de 2026, com janeiro e fevereiro também simulados para que o funil já chegue cheio em março. Os arquivos reproduzem os números do caso apresentados no capítulo 3: 3.051 oportunidades por mês, 2,99% de conversão de oportunidade em contrato, 30,8% sem nenhum contato em 72 horas e custo de aquisição entre R\$ 1.004 e R\$ 1.276 ao mês.

Cada origem vem no formato do próprio sistema, e não num formato já pronto para análise. A Meta informa o valor gasto como texto e identifica a campanha por um código numérico de quinze dígitos; o CRM não guarda esse código, apenas a identificação de origem do link (UTM). Entre os leads pagos, 6,8% chegam sem UTM alguma e 2,0% chegam com o texto `{{campaign.name}}` literal, um marcador que a plataforma deixou de substituir. As planilhas comerciais, por sua vez, são tabelas digitadas à mão, sem chave que as ligue ao CRM além do código do colaborador. Resolver essas diferenças é justamente o trabalho do processo de integração.

Quadro 2 – Bases de dados de origem

Origem	Arquivos	Conteúdo	Registros
CRM	oportunidades	Oportunidades com origem, UTM, datas de criação, primeiro contato e fechamento, responsáveis, resultado e plano contratado	19.280
CRM	equipe_comercial	Cadastro do time comercial, com função, tier e data de admissão	30
Meta Ads	insights_campanhas_diario	Impressões, cliques, leads e valor gasto, por campanha e dia	920
Planilhas comerciais	metas_mensais	Meta mensal de cada colaborador, por tipo de meta	180
Planilhas comerciais	faixas_comissao	Percentual de comissão por faixa de venda anual, com a trava de caixa	5
Planilhas comerciais	regras_bonus	Regras de bônus por papel do time comercial	6

Fonte: elaborado pelos autores (2026).

5.2 Ferramenta Utilizada na Geração

Os dados não foram baixados de nenhuma fonte: foram escritos por um programa, e esse programa foi construído com apoio de ferramenta de inteligência artificial generativa. O grupo utilizou o **Claude**, da Anthropic, pelo assistente de linha de comando Claude Code, com o modelo Opus, em **plano pago** — o plano gratuito não dá acesso a essa ferramenta.

O trabalho não partiu de um único comando. Foi conduzido em várias sessões: o grupo escreveu primeiro as regras do negócio e os números do caso, a ferramenta produziu o programa gerador, e cada rodada foi conferida contra os números declarados no capítulo 3, com ajuste do programa quando o resultado divergia. O pedido central, consolidado, foi o seguinte:

Escreva um programa em Python, com semente fixa, que gere as bases sintéticas de três origens de uma empresa de software de gestão vendido por assinatura: o CRM, com oportunidades percorrendo um funil de nove fases, atendidas por pré-vendedores e vendedores de níveis diferentes; a plataforma de anúncios da Meta, com desempenho diário por campanha; e as planilhas do time comercial, com metas mensais, faixas de comissão e regras de bônus. Cada arquivo deve sair no formato do próprio sistema de origem, e não num formato já pronto para análise: o valor gasto da Meta como texto, a campanha identificada por código numérico, e o CRM guardando apenas a UTM — com 7% dos leads pagos chegando sem UTM e 2% com o marcador de campanha não substituído. A janela é de seis meses, de março a agosto de 2026, com dois meses anteriores simulados para o funil chegar cheio. O resultado precisa reproduzir os números do caso: cerca de 3.000 oportunidades por mês, 3% de conversão de oportunidade em contrato e 31% sem nenhum contato em 72 horas.


O programa resultante está no repositório indicado no capítulo 9, com a semente fixada, de modo que qualquer pessoa pode executá-lo e obter exatamente os mesmos arquivos descritos no Quadro 2.

6 MODELAGEM DOS DADOS

6.1 Modelo Conceitual

A Figura 1 representa o negócio como conjuntos de entidades e as relações entre eles. Três relações são centrais para o problema. A ligação entre campanha e oportunidade é opcional, porque parte das oportunidades chega sem origem — é por isso que hoje não se sabe o custo de aquisição por canal. A oportunidade é atendida por colaboradores, o pré-vendedor que faz o primeiro contato e o vendedor que fecha, e cada oportunidade ganha registra o plano contratado e o valor do contrato. Por fim, cada colaborador tem uma meta por mês, o que liga o time comercial às planilhas e permite apurar a comissão sobre o que foi assinado.

Figura 1 – Modelo conceitual



Fonte: elaborado pelos autores (2026).

6.2 Modelo do Armazém de Dados

No destino, os dados são organizados em modelo estrela: tabelas de fato, que registram os acontecimentos medidos, cercadas por tabelas de dimensão, que descrevem por quais ângulos esses fatos são analisados (KIMBALL; ROSS, 2013). Os três fatos não são do mesmo tipo, e isso define como cada um é carregado. O fato da oportunidade é um *snapshot* acumulado: a mesma linha guarda as datas de criação, de primeiro contato e de fechamento, e é reescrita conforme a negociação avança. O fato do investimento é transacional diário, uma linha por campanha e dia, que nunca muda depois de gravada. O fato da meta é um *snapshot* periódico, fechado uma vez por mês.

Quadro 3 – Tabelas do armazém de dados

Tabela	Tipo	Uma linha por	Uso no problema
fato_oportunidade	Fato — <i>snapshot</i> acumulado	Oportunidade	Tempo até o primeiro contato e conversão por canal, plano e perfil — base para ordenar a fila
fato_investimento_anuncio	Fato — transacional diário	Campanha por dia	Investimento em mídia por campanha — base do custo de aquisição
fato_meta_vendedor	Fato — <i>snapshot</i> periódico	Colaborador por mês	Meta contra realizado e faixa de comissão
dim_data	Dimensão	Dia	Calendário comum a todos os fatos
dim_campanha	Dimensão	Campanha	Plataforma, nome e UTM — liga o anúncio à oportunidade
dim_plano	Dimensão	Plano	Mensalidade e perfil de cliente
dim_colaborador	Dimensão	Colaborador	Função, tier e time

Fonte: elaborado pelos autores (2026).

A dimensão do plano não vem de nenhuma das três origens: é uma tabela de referência, com os três planos do Quadro 1, carregada uma única vez. As demais dimensões são extraídas das origens e mantidas sem histórico de alteração nesta etapa, o que é suficiente porque a janela de dados é de seis meses e nenhum atributo dimensional muda dentro dela.

7 ARQUITETURA E INTEGRAÇÃO

7.1 Infraestrutura

Quadro 4 – Componentes da arquitetura

Componente	Escolha	Motivo
Nuvem	Amazon Web Services (AWS), pelo laboratório do AWS Academy, região Norte da Virgínia (us-east-1)	O laboratório dá à turma um orçamento fechado e só libera as regiões us-east-1 e us-west-2
Armazenamento bruto	Amazon S3	Guarda os arquivos como chegaram, separados por origem e data de carga, o que permite reprocessar
SGBD	PostgreSQL no Amazon RDS	Banco relacional com SQL padrão; backup e atualização ficam a cargo da AWS
Contêineres	Docker e Docker Compose	O mesmo ambiente roda na máquina de cada integrante e na nuvem
Orquestração	Apache Airflow, em contêiner, numa máquina Amazon EC2 t4g.small ligada sob demanda	Ferramenta aberta e padrão de mercado; a versão gerenciada da AWS custaria cerca de US\$ 212 por mês, mais de quatro vezes o orçamento inteiro do laboratório
Linguagens e bibliotecas	Python (pandas, boto3, SQLAlchemy) e SQL	Extração e carga em Python; transformação em SQL
Repositório	GitHub	Código do gerador, dos fluxos do Airflow e dos scripts SQL

Fonte: elaborado pelos autores (2026).


7.2 Processo de Integração

O processo, representado na Figura 2, é particionado por dia: cada execução trata um único dia de dados, identificado pela data de referência que o Airflow passa à tarefa. São cinco passos:

- **Extração:** os registros daquele dia são coletados em cada origem.
- **Camada bruta:** o que foi extraído é gravado sem alteração no S3, numa pasta com o nome da origem e a data de referência.
- **Staging:** os arquivos são carregados em tabelas espelho no PostgreSQL, uma para cada arquivo de origem.
- **Transformação:** comandos SQL padronizam tipos e unidades (o valor gasto da Meta, que vem como texto, torna-se número), ligam cada oportunidade à campanha pela UTM, tratam as oportunidades sem UTM e as que trazem o marcador não substituído, calculam o tempo até o primeiro contato e gravam o resultado no modelo estrela.
- **Conferência:** a cada execução, o número de registros lidos na origem é comparado com o número gravado no destino.

Como os dados são sintéticos e a janela é fechada, não existe carga nova chegando todo dia: a execução real é um *backfill*, em que o Airflow roda a mesma tarefa uma vez para cada um dos 184 dias da janela. É por isso que cada passo precisa ser idempotente — reprocessar um dia tem que sobrescrever aquele dia, nunca duplicá-lo. Numa operação contínua, a mesma rotina rodaria uma vez ao dia, sem alteração nenhuma no código.

Figura 2 – Arquitetura do processo de integração



Fonte: elaborado pelos autores (2026).

8 CUSTOS

O projeto roda no laboratório do AWS Academy, que dá à turma um orçamento fechado de **US\$ 50** para todo o semestre. Esse limite é rígido: esgotado o orçamento, a conta é desativada e o trabalho armazenado nela se perde. Não há, portanto, a folga de uma conta comum, em que o estouro apenas passa a ser cobrado. É essa restrição, e não o preço de tabela, que define a arquitetura.

O volume de dados é irrelevante para o custo — os seis arquivos de origem somam menos de 6 MB. O que custa é o tempo em que as máquinas ficam ligadas. Por isso nem a EC2 nem o banco ficam de pé: ambos são iniciados quando há trabalho a fazer e desligados em seguida. O Quadro 5 compara esse regime com o de máquinas sempre ligadas, pelos preços sob demanda da região escolhida (AMAZON WEB SERVICES, 2026a; 2026b).

Quadro 5 – Consumo mensal estimado no laboratório (us-east-1)

Serviço	Configuração	Preço	Sob demanda, ~10 h/mês (US\$)	Sempre ligado (US\$)
Amazon EC2	t4g.small, 2 processadores e 2 GB	US\$ 0,0168/h	0,17	12,26
Amazon RDS for PostgreSQL	db.t4g.micro	US\$ 0,016/h	0,16	11,68
Endereço IP público	cobrado enquanto a máquina está ligada	US\$ 0,005/h	0,05	3,65
Disco da máquina (EBS gp3)	10 GB	US\$ 0,08/GB ao mês	0,80	0,80
Armazenamento do banco	20 GB	US\$ 0,115/GB ao mês	2,30	2,30
Amazon S3	menos de 1 GB	US\$ 0,023/GB ao mês	0,02	0,02
Total por mês			3,50	30,71

Fonte: elaborado pelos autores com base nos preços da AWS (2026).

De setembro a dezembro, o regime sob demanda consome cerca de **US\$ 9 dos US\$ 50** disponíveis. Com as duas máquinas sempre ligadas, o mesmo período custaria cerca de US\$ 77 e estouraria o orçamento antes da última etapa.

Duas consequências merecem registro. A primeira é que o piso do custo é o armazenamento: disco de máquina desligada e armazenamento de banco parado continuam sendo cobrados, e somam US\$ 3,10 por mês independentemente de uso — ou seja, 89% do consumo previsto. A segunda é que o maior risco não é técnico, e sim de esquecimento: um banco deixado ligado por um mês consome US\$ 14, mais do que o projeto inteiro. Como o indicador de saldo do laboratório é alimentado pelo serviço de orçamentos da AWS e atrasa de oito a doze horas (AMAZON WEB SERVICES, 2026c), ele não serve de alarme. A proteção é procedimental e está no próprio pipeline: a última tarefa do fluxo desliga a máquina de processamento, e o encerramento de cada sessão de trabalho para o banco.

9 REPOSITÓRIO

O código do projeto está disponível em: <https://github.com/grupotbd19h-rgb/eixo4-nexo-sistemas>.

O repositório reúne o programa que gera as bases sintéticas das três origens, o programa que desenha os diagramas, o gerador deste documento e os arquivos de dados produzidos. Os fluxos do Airflow e os comandos SQL da transformação serão acrescentados na Etapa 3, quando o pipeline for implementado.

10 REFERÊNCIAS

AMAZON WEB SERVICES. Amazon EC2 On-Demand Pricing. 2026a. Disponível em: <https://aws.amazon.com/ec2/pricing/on-demand/>. Acesso em: 24 set. 2026.

AMAZON WEB SERVICES. Amazon RDS for PostgreSQL Pricing. 2026b. Disponível em: <https://aws.amazon.com/rds/postgresql/pricing/>. Acesso em: 24 set. 2026.

AMAZON WEB SERVICES. AWS Academy Learner Lab: educator guide. 2026c. Disponível em: <https://d1.awsstatic.com/AWS%20Academy%20Learner%20Lab%20Educator%20Guide.pdf>. Acesso em: 24 set. 2026.

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Brasília, DF: Presidência da República, 2018. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm. Acesso em: 30 ago. 2026.

CASTELLS, Manuel. A sociedade em rede. São Paulo: Paz e Terra, 1999. (A era da informação: economia, sociedade e cultura, v. 1).

KIMBALL, Ralph; ROSS, Margy. The data warehouse toolkit: the definitive guide to dimensional modeling. 3. ed. Indianapolis: Wiley, 2013.