

Pontifícia Universidade Católica de Minas Gerais
Tecnologia em Banco de Dados - EAD
Graduação Virtual

Alberto Santana Santos
Alessandro Junio Lopes Rodrigues
Gabriel Figueiredo do Nascimento
João Victor de Andrade Guedes
Lucas Naves da Silveira
Luiza Gonçalves Zacarias

**Plataforma de dados para priorização de leads e análise do custo de
aquisição de clientes**

Etapa 2 — Replicação e integração dos dados

Projeto apresentado ao Curso de Tecnologia em Banco de Dados da Pontifícia Universidade Católica de Minas Gerais, como requisito parcial da Etapa 2 do Projeto de Big Data Analytics — Eixo 4.

Orientador: Prof. Marco Paulo

Belo Horizonte
2026

SUMÁRIO

1 INTRODUÇÃO	3
2 A EMPRESA	3
2.1 Ramo de Atuação, Porte e Produtos	3
2.2 Recursos de TI	3
3 O PROBLEMA	4
4 A EMPRESA E A SOCIEDADE DIGITAL	4
5 BASES DE DADOS	5
6 MODELAGEM DOS DADOS	6
6.1 Modelo Conceitual	6
6.2 Modelo do Armazém de Dados	7
7 ARQUITETURA E INTEGRAÇÃO	7
7.1 Infraestrutura	8
7.2 Processo de Integração	8
8 CUSTOS	9
9 REPOSITÓRIO	9
10 REFERÊNCIAS	10

1 INTRODUÇÃO

Castells (1999) caracteriza a sociedade contemporânea como uma sociedade em rede: a informação se torna a matéria-prima da atividade econômica, e a rede, viabilizada pelas tecnologias de informação e comunicação, passa a ser a forma predominante de organizar a produção, o trabalho e o consumo. Nessa configuração, a tecnologia não é algo que se acrescenta a um negócio já formado — é em torno dela que o negócio se estrutura.

A Nexo Sistemas, organização **fictícia** tomada como objeto deste projeto, vende software de gestão por assinatura para pequenas empresas do varejo e se caracteriza como empresa dessa sociedade em rede em todas as frentes. Vende à distância, sem visita presencial; entrega um produto que só funciona em nuvem; e encontra seus clientes por busca e anúncio na internet, em plataformas de mídia cujas regras não controla. Mais do que isso, o que ela vende é a digitalização de outros negócios: cada contrato fechado tira um pequeno lojista do caderno e da planilha e o coloca num sistema conectado.

O projeto consiste em construir, para ela, uma plataforma de dados que reúna informações hoje espalhadas em sistemas separados, de modo que a empresa consiga priorizar o atendimento aos interessados com maior chance de fechar negócio e saber quanto custa, em cada canal, conquistar um cliente.

2 A EMPRESA

2.1 Ramo de Atuação, Porte e Produtos

A Nexo Sistemas atua no ramo de desenvolvimento e licenciamento de software. Seu produto reúne frente de caixa, controle de estoque, emissão de notas fiscais e gestão financeira, e é vendido por assinatura mensal. Foi fundada em 2016, fica em Belo Horizonte e opera de forma remota: a venda é feita à distância, por um time comercial próprio, e a implantação acontece sem visita presencial.

A empresa tem **70 funcionários**: 30 na área comercial, 18 em desenvolvimento, 12 em suporte e 10 no administrativo, financeiro e TI. Atende cerca de 2.500 clientes e fecha aproximadamente mil novos contratos por ano, com receita anual em torno de R\$ 10,9 milhões. Pelo número de funcionários e pelo faturamento, é classificada como **média empresa**.

São vendidos três planos de assinatura, que se diferenciam pelo porte do cliente e pelos recursos liberados.

Quadro 1 – Produtos comercializados

Plano	Mensalidade (R\$)	Perfil de cliente	Clientes ativos
Essencial	190	Microempresas e autônomos	1.100
Profissional	390	Pequenas empresas	1.150
Corporativo	990	Médias empresas e redes de lojas	250

Fonte: elaborado pelos autores (2026).

2.2 Recursos de TI

A empresa não tem servidores próprios. O produto e os sistemas internos rodam em nuvem contratada como serviço, e o hardware se resume aos notebooks dos funcionários, aos headsets do time comercial e ao link de internet da sede.

Em software, a operação comercial se apoia em quatro fontes de informação, mantidas separadamente, que serão as origens de dados do projeto:

- **CRM**, com os contatos, as oportunidades e as etapas da venda;
- **Plataformas de anúncios**, com o quanto foi investido e o que cada campanha trouxe;
- **Plataforma de cobrança**, com os planos contratados, as faturas, os pagamentos e os cancelamentos;
- **Planilhas do time comercial**, com as metas de cada vendedor, as faixas de comissão e a apuração refeita à mão todo mês.

Há ainda a base de uso do próprio produto, que registra o que cada cliente faz no sistema. É a maior de todas em quantidade de registros, mas hoje não é aproveitada fora do suporte.

Em serviços de TI, quase tudo é contratado por assinatura, mais o suporte técnico terceirizado e a hospedagem em nuvem. A equipe de tecnologia cuida só do produto: não existe ninguém dedicado a dados na operação comercial.

3 O PROBLEMA

A Nexo recebe cerca de 3.000 oportunidades de venda por mês e fecha negócio com 3% delas. O time comercial atende por ordem de chegada, e não por quem tem mais chance de comprar, simplesmente porque não existe critério para ordenar a fila: 31% do que entra não recebe nenhum contato em 72 horas, justo o período em que o interesse ainda está quente.

Ao mesmo tempo, o custo para conquistar um cliente — somando o investimento em anúncios e a comissão paga na venda — subiu de R\$ 900 para R\$ 1.450 em dois anos, e a empresa não consegue dizer qual canal ou qual plano está puxando essa alta. O motivo é sempre o mesmo: o investimento em anúncio está numa plataforma, o histórico da negociação está no CRM, o dinheiro que entrou está na cobrança, e nada disso se conversa. Pelo mesmo motivo, a comissão do time comercial é reapurada à mão a cada virada de mês.

O projeto pretende responder a duas perguntas: como ordenar a fila de atendimento por chance de conversão, e quanto custa conquistar um cliente em cada canal e em cada plano. Para isso, os dados do funil serão gerados de forma sintética, reproduzindo só a estrutura do negócio.

4 A EMPRESA E A SOCIEDADE DIGITAL

Hoje a Nexo usa tecnologia só para operar, não para decidir. Com a plataforma de dados, isso muda de três formas. O trabalho do vendedor muda, porque ele deixa de escolher a quem ligar e passa a seguir uma fila ordenada. As competências mudam, porque a empresa vai precisar de gente de dados, função que hoje não existe. E a responsabilidade aumenta, porque juntar num só lugar os dados de todos os

sistemas cria um ponto único de risco, o que exige controle de acesso e regra clara sobre por quanto tempo cada dado é guardado.

Do lado da sociedade, o ponto sensível é quem a empresa decide atender primeiro. Uma fila ordenada por potencial econômico tende a priorizar o cliente maior e deixar o microempreendedor para o final — justamente quem mais ganharia com o controle que o produto oferece. Por isso o grupo assume desde já duas regras: a ordenação organiza a fila, mas não exclui ninguém dela, garantindo um prazo máximo para o primeiro contato; e o critério usado para ordenar fica documentado e aberto ao time comercial. Vale lembrar ainda que a lei brasileira garante ao cliente o direito de pedir revisão de decisões tomadas só por máquina (BRASIL, 2018).

Na outra direção, a sociedade digital também mexe com a empresa. Mudanças em obrigações fiscais eletrônicas provocam picos de procura por sistemas de gestão, e ela precisa antecipar isso para dimensionar equipe e verba de anúncio. E como depende de plataformas de mídia cujas regras mudam sem aviso, seu custo de aquisição é em parte decidido por terceiros — o que reforça a necessidade de ter medição própria.

5 BASES DE DADOS

Como a Nexo é fictícia, os dados das quatro origens foram gerados por um programa em Python, com semente fixa: rodar de novo produz exatamente os mesmos arquivos. Eles cobrem 24 meses, de setembro de 2024 a agosto de 2026, e reproduzem os números do caso: cerca de 3.000 oportunidades por mês, 3% de conversão, 31% sem contato em 72 horas, 2.500 clientes ativos e custo de aquisição subindo de cerca de R\$ 950 para R\$ 1.490.

Cada origem vem no formato do próprio sistema, e não num formato já pronto para análise. O Google Ads informa o custo em milionésimos de real, a Meta informa o valor gasto como texto e o CRM não guarda o código da campanha, só a identificação de origem do link (UTM) — e 6% das oportunidades chegam sem ela. Resolver essas diferenças é justamente o trabalho do processo de integração.

Quadro 2 – Bases de dados de origem

Origem	Arquivos	Conteúdo	Registros
Google Ads	campanhas_desempenho_diario	Impressões, cliques, conversões e custo, por campanha e dia	2.920
Meta Ads	insights_campanhas_diario	Impressões, cliques, leads e valor gasto, por campanha e dia	2.920
CRM	oportunidades; equipe_comercial	Oportunidades com origem, datas de criação, primeiro contato e fechamento, responsáveis e resultado; cadastro do time comercial	72.096; 30
Plataforma de cobrança	planos; clientes; assinaturas; faturas; pagamentos; cancelamentos	Planos contratados, faturas mensais, cada pagamento recebido e os cancelamentos com motivo	3; 4.686; 4.686; 62.880; 60.862; 2.174
Planilhas comerciais	metas_mensais; faixas_comissao	Meta mensal de cada vendedor e percentual de comissão por faixa de atingimento	480; 5


Fonte: elaborado pelos autores (2026).

6 MODELAGEM DOS DADOS

6.1 Modelo Conceitual

A Figura 1 representa o negócio como conjuntos de entidades e as relações entre eles. Três relações são centrais para o problema. A ligação entre campanha e oportunidade é opcional, porque parte das oportunidades chega sem origem — é por isso que hoje não se sabe o custo de aquisição por canal. A oportunidade é atendida por colaboradores (o pré-vendedor, que faz o primeiro contato, e o vendedor, que fecha), e só a oportunidade ganha gera um cliente. Por fim, cada fatura guarda seus pagamentos, o que permite calcular a comissão tanto sobre a venda assinada quanto sobre o dinheiro efetivamente recebido.

Figura 1 – Modelo conceitual



Fonte: elaborado pelos autores (2026).

6.2 Modelo do Armazém de Dados

No destino, os dados são organizados em modelo estrela: tabelas de fato, que registram os acontecimentos medidos, cercadas por tabelas de dimensão, que descrevem por quais ângulos esses fatos são analisados (KIMBALL; ROSS, 2013).

Quadro 3 – Tabelas do armazém de dados

Tabela	Tipo	Uma linha por	Uso no problema
fato_oportunidade	Fato	Oportunidade	Tempo até o primeiro contato e conversão por canal, plano e perfil — base para ordenar a fila
fato_investimento_anuncio	Fato	Campanha por dia	Investimento de Google e Meta numa só tabela — base do custo de aquisição
fato_fatura	Fato	Fatura	Receita faturada e recebida, e atraso
fato_assinatura	Fato	Assinatura	Clientes ativos, plano e cancelamento
fato_meta_vendedor	Fato	Vendedor por mês	Meta contra realizado e faixa de comissão
dim_data	Dimensão	Dia	Calendário comum a todos os fatos
dim_campanha	Dimensão	Campanha	Plataforma, nome e UTM — liga o anúncio à oportunidade
dim_plano	Dimensão	Plano	Mensalidade e perfil de cliente
dim_colaborador	Dimensão	Colaborador	Função e time
dim_cliente	Dimensão	Cliente	Segmento, porte e estado

Fonte: elaborado pelos autores (2026).

7 ARQUITETURA E INTEGRAÇÃO

7.1 Infraestrutura

Quadro 4 – Componentes da arquitetura

Componente	Escolha	Motivo
Nuvem	Amazon Web Services (AWS), região Norte da Virgínia (us-east-1)	A conta nova recebe créditos que cobrem o semestre, e a região é a de menor preço
Armazenamento bruto	Amazon S3	Guarda os arquivos como chegaram, separados por origem e data de carga, o que permite reprocessar
SGBD	PostgreSQL no Amazon RDS	Banco relacional com SQL padrão; backup e atualização ficam a cargo da AWS
Contêineres	Docker e Docker Compose	O mesmo ambiente roda na máquina de cada integrante e na nuvem
Orquestração	Apache Airflow, em contêiner, numa máquina Amazon EC2	Ferramenta aberta e padrão de mercado; a versão gerenciada da AWS custaria cerca de US\$ 212 por mês
Linguagens e bibliotecas	Python (pandas, boto3, SQLAlchemy) e SQL	Extração e carga em Python; transformação em SQL
Repositório	GitHub	Código do gerador, dos fluxos do Airflow e dos scripts SQL


Fonte: elaborado pelos autores (2026).

7.2 Processo de Integração

O processo, representado na Figura 2, roda uma vez por dia, disparado pelo Airflow:

- **Extração:** os arquivos de cada origem são coletados.
- **Camada bruta:** cada arquivo é gravado sem alteração no S3, numa pasta com o nome da origem e a data da carga.
- **Staging:** os arquivos são carregados em tabelas espelho no PostgreSQL, uma para cada arquivo.
- **Transformação:** comandos SQL padronizam unidades e datas (o custo do Google é dividido por um milhão, o valor gasto da Meta vira número), ligam cada oportunidade à campanha pela UTM, calculam o tempo até o primeiro contato e gravam o resultado no modelo estrela.
- **Conferência:** a cada carga, o número de registros na origem é comparado com o número gravado no destino.

Figura 2 – Arquitetura do processo de integração



Fonte: elaborado pelos autores (2026).

8 CUSTOS

A conta nova da AWS entra no plano gratuito, que dá até US\$ 200 em créditos por seis meses e só permite máquinas de uma lista reduzida (AMAZON WEB SERVICES, 2026a). Por isso foram escolhidas uma máquina c7i-flex.large (2 processadores e 4 GB de memória, o mínimo recomendável para o Airflow) e um banco db.t4g.micro, ambos incluídos no plano. O Quadro 5 mostra o custo mensal pelos preços sob demanda da região escolhida (AMAZON WEB SERVICES, 2026b; 2026c).

Quadro 5 – Estimativa de custo mensal na AWS (us-east-1)

Serviço	Configuração	Ligado 24 h/dia (US\$)	Máquina ligada 12 h/dia (US\$)
Amazon EC2	c7i-flex.large, US\$ 0,0848/h	61,90	30,95
Disco da máquina (EBS gp3)	30 GB, US\$ 0,08/GB	2,40	2,40
Amazon RDS for PostgreSQL	db.t4g.micro, US\$ 0,016/h	11,68	11,68
Armazenamento do banco	20 GB, US\$ 0,115/GB	2,30	2,30
Endereço IP público	US\$ 0,005/h	3,65	3,65
Amazon S3	Menos de 1 GB, US\$ 0,023/GB	0,02	0,02
Total		81,95	51,00

Fonte: elaborado pelos autores com base nos preços da AWS (2026).

Com a máquina ligada o dia inteiro, o período de setembro a dezembro custaria cerca de US\$ 225, acima dos créditos. Com a máquina ligada só 12 horas por dia — o suficiente para a carga diária e para o trabalho do grupo —, o custo cai para cerca de US\$ 140. Para não haver surpresa, a conta terá alertas de orçamento, que são gratuitos, avisando o grupo ao atingir US\$ 50 e US\$ 150.

9 REPOSITÓRIO

O código do projeto está disponível em: [INSERIR LINK DO REPOSITÓRIO DO GRUPO NO GITHUB].

10 REFERÊNCIAS

AMAZON WEB SERVICES. AWS Free Tier FAQs. 2026a. 2026. Disponível em: <https://aws.amazon.com/free/free-tier-faqs/>. Acesso em: 14 set. 2026.

AMAZON WEB SERVICES. Amazon EC2 On-Demand Pricing. 2026. Disponível em: <https://aws.amazon.com/ec2/pricing/on-demand/>. Acesso em: 14 set. 2026.

AMAZON WEB SERVICES. Amazon RDS for PostgreSQL Pricing. 2026. Disponível em: <https://aws.amazon.com/rds/postgresql/pricing/>. Acesso em: 14 set. 2026.

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Brasília, DF: Presidência da República, 2018. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm. Acesso em: 30 ago. 2026.

CASTELLS, Manuel. A sociedade em rede. São Paulo: Paz e Terra, 1999. (A era da informação: economia, sociedade e cultura, v. 1).

KIMBALL, Ralph; ROSS, Margy. The data warehouse toolkit: the definitive guide to dimensional modeling. 3. ed. Indianapolis: Wiley, 2013.